RAGAS Diagnostic Report - PayPilot

1. Контекст

Рішення CTO: спочатку відновити цілісність таблиць і видачу; дорожча модель не усуває доведене обрізання. Мандат: **Ship it** для навчального eval, без висновку про готовність реальних платежів.

2026-10-17; Anthropic / claude-haiku-5-5; stand-shared 86a22ea. Корпус: 21 документ Verta; kb_clean за секціями, kb_broken по 160 символів; профілі clean/lesson-04. Golden: **47 кейсів, 10 retrieval**, hash 97dc8e0936fa. Daily: clean **42/42**, lesson-04 **34/42**; 5 human/release не оцінювалися. Прогноз v2: 88749f8, до обох серій. Лабораторна: 26 запитів; докази й розмітка: додаток.

2. Локалізація

Випадок	Симптом і точка відмови	Доказ із trace
Вправа 1, broken-контроль	Частина тарифу; **індексація**	tariffs.md#b3: «Tier 3 ... 0.5% ... EUR 5»; кінець «,000» відрізано
Вправа 2, k=3	Половина відповіді; **видача**	tariffs.md#s2 дає 0.9%; limits.md#s1 відсутній, daily 20,000 не прийшов
Вправа 3, D25	Вхід правильний, підсумок хибний; **генерація**	Пошуку немає; quote_fx.final_amount=6463.043478, відповідь 6500
Вправа 4, D05	Агент не шукав; **генерація**	Немає tool.search_knowledge_base; помилковий довідник у prompt
C-13	Точний симптом **не відтворюється**	2 нові сесії: tariffs.md#b3 обрізаний, але EUR 1,500 агент не вигадав
C-14	Список без window; **видача**	disputes.md#b1 / disputes-process.md#b1 не містять 60; повного рядка не видано

Розподіл: індексація **1**, видача **2**, генерація **2**, не відтворюється **1**. Для скарг CUS-0002 - навчальне припущення; запити реконструйовані. Обрізання в C-13 доведено окремо від невідтвореного точного симптому.

3. Доказ причини

Жива пара cause-clean/cause-broken: однакові clean, prompt, модель, k=1, CUS-0003, clock і питання «what FX spread applies to my account and what is my free monthly conversion allowance?». Змінено лише **index**. R/P нижче - за сукупністю унікальних retrieved fragments; F - за атомарними фактичними твердженнями відповіді.

Метрика	kb_clean	kb_broken	Дельта
Recall	0 з 2 = 0	1 з 2 = 0.5	+0.5
Precision	0 з 1 = 0	1 з 2 = 0.5	+0.5
Faithfulness до retrieval	2 з 12 = 0.167	1 з 2 = 0.5	+1/3

Очікуваного погіршення ця пара **не показала**: перший однаковий query дав FX-довідник без цільових чисел; далі clean викликав quote, broken повторив пошук. Низька F clean не означає хибні числа: 10 тверджень спираються на tools, а не retrieval. Детальна розмітка не змішує ці джерела.

Окремий **offline** контроль із фактичним query «FX conversion spread by tier and free monthly allowance», k=1: tariffs.md#s2 проти #b3; R **2/2=1** → **1/2=0.5**, delta -0.5; P **1/1=1** → **1/1=1**, delta 0; F - без відповіді не оцінюється. Висновок: фіксований пошук доводить втрату кінця таблиці саме **під час індексації**, а не доводить універсальне погіршення всіх живих відповідей.

4. Зворотний випадок

Clean, CUS-0005, «конвертувати шість тисяч євро в долари з повним розрахунком». Контроль: **6463.04 USD**; D25: **6500 USD у 5 з 5 = 1.0** прогонів при незмінному quote_fx.final_amount=6463.043478. Overlay наказує округлювати підсумок угору до сотні, не узгоджувати з компонентами й не показувати точне число. Інструмент правильний, помилка з'являється у відповіді: генерація.

Контроль D05, CUS-0008, «комісію за SWIFT»: пошуку немає, відповідь «EUR 15, відсоткової комісії немає»; tariffs.md#s3 задає **EUR 15 + 0.3%**, clean це відтворив. Для D25/D05 R/P/F до retrieval = **-**, бо retrieved context відсутній; звірка з tool/корпусом - окрема перевірка.

5. Компроміс

Clean / kb_clean / без клієнта; питання про spread і daily transfer limit Tier 2. Еталон: tariffs.md#s2 (0.9%) та limits.md#s1 (20,000 EUR). Кожне значення - 3 незалежні сесії; числа у клітинках наведено по прогонах.

k	Recall	Precision	Повна відповідь	Input tokens
3	1/2; 1/2; 1/2	1/3; 1/3; 1/3	0 з 3	5985; 5987; 5985
4	1/2; 1/2; 2/2	1/4; 1/4; 2/4	1 з 3	6133; 6119; 6315
5	2/2; 2/2; 2/2	2/5; 2/5; 2/5	3 з 3	6343; 6386; 6416

При k4 англійський query знайшов обидва факти, два українські - лише spread. Обираю **k5**: середній input 6381.67 проти 6189, **+3.11%**, три зайві фрагменти з п'яти; прийнятний обмін під Ship it, не гарантія за трьома повторами. На kb_broken при k1 і k5 tariffs.md#b4 не прийшов; правильний allowance у відповіді k5 походить із quote, тож більша видача індекс не полагодила.

6. Рішення й межі

Точка	Виправлення	Реальна ціна*	Компроміс	Промпт допоможе?
Індексація	Цілі таблиці, заголовки з рядками; переіндексація	4 год інженера + 3 год обчислень; $136 за сценарієм нижче	Більші chunks, повторний regression	Ні: відсутній текст не відновить
Видача	k5; нормалізація query; перевірка reranking	Припущення: 2 год × $30 = $60; k5: +3.11% input; reranker окремо	Зайві фрагменти, latency	Ні: retrieval-конфіг і алгоритм треба змінити
Генерація	Прибрати D05/D25, звіряти число відповіді з tool	Припущення: 4 год × $30 = $120 + regression-виклики	Більше перевірок/відмов, latency	Так для prompt-дефекту; без гарантії числової коректності

*Планова оцінка, не ринкова пропозиція: 100,000 документів × 1000 tokens; chunks по 500 без overlap, 200,000 chunks. Припускаємо embedding $0.10/M tokens: $10; compute 3 год × $2: $6; інженер 4 год × $30: $120; **$136**, 3 год машинного часу плюс 4 год роботи. Обсяг, ставки й продуктивність - явні припущення, не виміри PayPilot.

Промптом не лікуються розрізані рядки та невиданий фрагмент. **Залишковий ризик D26:** точний переказ усіх умов спору може мати зелені R/P/F, але дія create_dispute відбутися попри restriction. Це сценарій межі метрик, не новий прогін D26. Наслідок - недозволений спір; приймаємо лише для retrieval-eval, перевірку дій тримаємо в engine/state suite, поза production це не дозвіл на реліз. C-13 лишається ризиком невідтвореного точного симптому.

Еталони - рядки локального корпусу, ніколи відповіді агента. **False confidence:** v2 RET-H01 зарахував гіпотетичні 5,000 як PASS; RET-H07 взяв 1.2% з prompt, не з retrieval. Тому lesson-04 **7/10 runner**, але лише **6/10** відповідей із потрібними підтвердженими числами за ручним розбором; це не context recall. Оцінка витрат користувача за сьогодні на момент повідомлення: **близько $0.21**, без звірки окремих викликів.

Останній рядок: обміняли контекст/токени на повноту через k5; не міняємо модель як виправлення індексу й не оголошуємо зелений L3 доказом правильних дій; переглянемо рішення після зміни корпусу/моделі, нових промахів або перевищення бюджету latency/tokens.